Contrastive Learning u implicitnim sistemima preporuke

Eksperimentalna analiza BPR i InfoNCE pristupa

Marina Vračarić

Matematički fakultet
Univerzitet u Beogradu

2026

Pregled

1. Contrastive Learning
2. Implicitni sistemi preporuke
3. Matrix Factorization
4. Bayesian Personalized Ranking
5. Negative sampling
6. Zaključak

Šta je kontrastivno učenje?

- **Kontrastivno učenje** je pristup učenju reprezentacija zasnovan na poredjenju pozitivnih i negativnih primera.
- Osnovna ideja je:
  - slični objekti treba da imaju **slične reprezentacije**
  - različiti objekti treba da budu **udaljeni u latentnom prostoru**
- Model uči tako što:
  - **približava** pozitivne parove
  - **udaljava** negativne parove
- Ovaj pristup se široko koristi u:
  - računarskom vidu
  - obradi teksta
  - sistemima preporuke

Intuicija kontrastivnog učenja

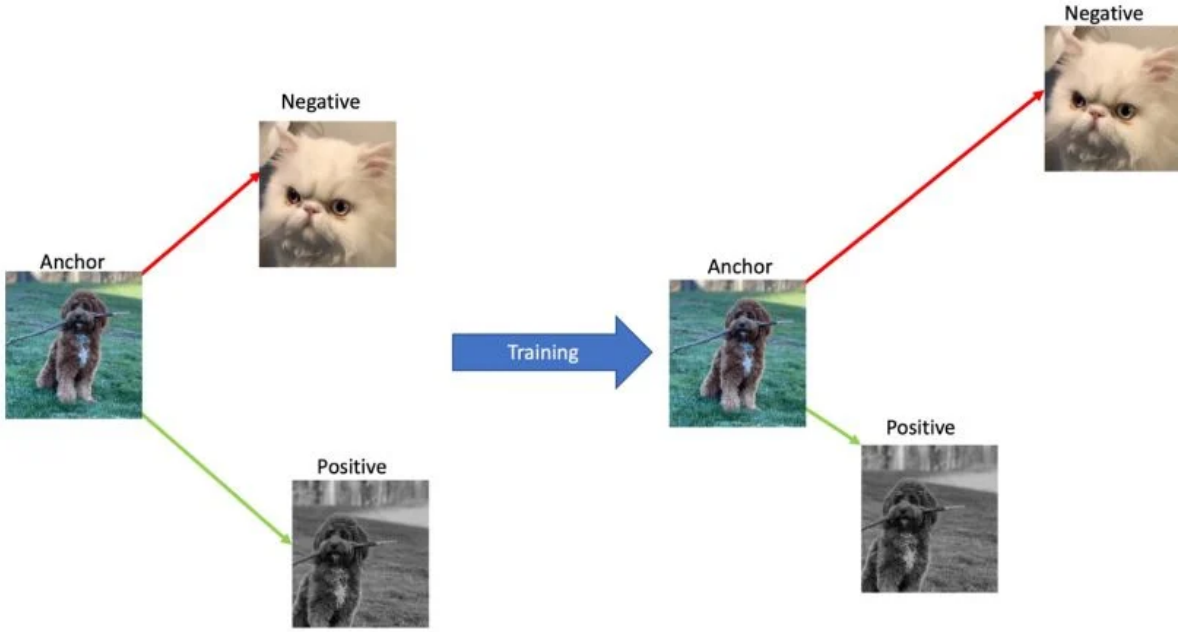

Model uči da približi pozitivne parove i udalji negativne.

Sistemi preporuke

- Sistemi preporuke su ključna komponenta modernih online platformi.
- Njihov cilj je da korisnicima preporuče relevantne stavke:
  - filmove
  - proizvode
  - muziku
  - sadržaj
- Jedan od najčešćih pristupa je **kolaborativno filtriranje**.
- Model uči preferencije korisnika na osnovu istorije interakcija.

Implicitne interakcije

- U mnogim realnim sistemima eksplicitne ocene nisu dostupne.
- Umesto toga koriste se **implicitne interakcije**:
  - klikovi
  - pregledi
  - kupovine
  - gledanje sadržaja
- Problem: ne znamo koje stavke korisnik zaista ne voli.
- Nedostatak negativnih primera otežava treniranje modela.
- U ovom domenu kontrastivno učenje smatra pozitivnim parom korisnika i film koji jeste gledao, a negativnim film koji nije gledao

Eksperimentalno okruženje

- Dataset: **MovieLens 100k**
- Sadrži:
  - 100000 ocena
  - 943 korisnika
  - 1682 filma
- Evaluacija modela vrši se pomoću:
  - Recall@10
  - NDCG@10
  - MRR

Evaluacione metrike

- **Recall@10**
  Procenat relevantnih filmova koji se pojavljuju medju prvih 10 preporuka.
- **NDCG@10**
  Mera kvaliteta rangiranja koja daje veću težinu relevantnim filmovima na vrhu liste preporuka.
- **MRR (Mean Reciprocal Rank)**
  Prosečna vrednost recipročnog ranga prvog relevantnog filma u listi preporuka.

Evaluation Metrics

NDCG@10

$$DCG@10 = \sum_{i=1}^{10} \frac{rel_i}{\log_2(i+1)}$$

$$NDCG@10 = \frac{DCG@10}{IDCG@10}$$

MRR

$$MRR = \frac{1}{|U|} \sum_{u=1}^{|U|} \frac{1}{rank_u}$$

Latentni modeli

- Popularan pristup u sistemima preporuke je **matrix factorization**.
- Svaki korisnik i svaki film se predstavlja latentnim vektorom:

$$s(u, i) = \mathbf{u}^\top \mathbf{i}$$

- Skor predstavlja procenu koliko je film relevantan korisniku.
- Model se trenira tako da pozitivne interakcije dobiju veći skor.

BPR loss

- BPR optimizuje relativni poredak preporuka.
- Za korisnika se formira trojka:

$$(u, i^+, i^-)$$

  - i^+ – film sa kojim je korisnik imao interakciju
  - i^- – film bez interakcije
- Cilj je da model nauči:

$$s(u, i^+) > s(u, i^-)$$

- BPR loss funkcija:

$$L = -\log \sigma(s(u, i^+) - s(u, i^-))$$

Model Training

Training sample

$$(u, i^+, i^-)$$

Forward pass

$$s(u, i) = \mathbf{u}^\top \mathbf{i}$$

$$\mathcal{L} = -\log \sigma \left(s(u, i^+) - s(u, i^-) \right)$$

Backpropagation

- compute gradients $\nabla \mathcal{L}$
- update embeddings using SGD

InfoNCE loss

- Jedna od najčešćih kontrastivnih funkcija gubitka je **InfoNCE**.
- Za dati pozitivni par (u, i) i skup negativnih primera:

$$L = -\log \frac{\exp(s(u,i)/\tau)}{\sum_j \exp(s(u,j)/\tau)}$$

- Parametar τ predstavlja **temperaturu**.
- On kontroliše koliko model razlikuje pozitivne i negativne primere.

Strategije negativnog uzorkovanja

- Negativni primeri se generišu uzorkovanjem filmova bez interakcije.
- Postoje različite strategije:
  - random negative sampling
  - hard negative sampling
  - in-batch negative sampling
  - symmetric in-batch negative sampling
  - curriculum pristup
- Hard negativi su filmovi koji su modelu veoma slični pozitivnim primerima.
- Oni pomažu modelu da nauči finije razlike izmeu stavki.

Random Negative Sampling

- Negativni primeri se biraju **nasumično** iz skupa stavki sa kojima korisnik nije imao interakciju.
- Najjednostavnija i najčešće korišćena strategija u implicitnim sistemima preporuke.

Prednosti

- jednostavna implementacija
- stabilan trening
- mali računski trošak

Mane

- mnogi negativni primeri su **previše laki**
- model ne uči razliku izmeu sličnih filmova

Hard Negative Sampling

- Negativni primeri se biraju medju stavkama koje su **najbliže pozitivnom primeru** u latentnom prostoru.
- To su filmovi koji deluju relevantno modelu, ali zapravo nisu pozitivni primeri.

Prednosti

- model uči preciznije razlike izmedju sličnih stavki
- poboljšava kvalitet rangiranja preporuka
- daje jači signal za učenje nego random negativi

Mane

- može dovesti do **nestabilnog treninga**
- povećava računski trošak zbog traženja najbližih stavki
- veći rizik od **false negative** primera

In-Batch Negative Sampling

- Negativni primeri se uzimaju iz **ostalih parova u minibatch-u**.
- Ako batch sadrži N parova (u, i):
  - svaki pozitivan par ima $N - 1$ negativnih primera

Prednosti

- veliki broj negativnih primera
- nema dodatnog uzorkovanja
- efikasna implementacija

Mane

- kvalitet negativnih primera zavisi od batch-a
- mali batch može dati slab signal za učenje

Symmetric Contrastive Learning

- Kontrastivni gubitak se računa u **oba smera**.
  - korisnik $\rightarrow$ film
  - film $\rightarrow$ korisnik
- Time model uči dve projekcije istovremeno.

Prednosti

- stabilnije učenje embedding prostora
- bolje učenje reprezentacija korisnika i stavki

Mane

- veći računski trošak
- duže vreme treniranja

Curriculum Negative Sampling

- Kombinuje različite strategije negativnog uzorkovanja tokom treninga.

Ideja

- početak treninga: **random negative sampling**
- kasnije faze: **hard negative sampling**

Prednosti

- stabilniji početak treninga
- model postepeno uči složenije razlike

Mane

- potrebno podešavanje trenutka prelaska izmedju strategija
- dodatna složenost implementacije

Poredjenje modela

Loss funkcija	Recall@10	NDCG@10	MRR
BPR	0.0954	0.0468	0.0439
Pairwise InfoNCE	**0.1522**	**0.0758**	**0.0691**
In-Batch InfoNCE	0.0574	0.0275	0.0294
Hard Negative	0.1137	0.0574	0.0516
Simetrični In-Batch	0.0636	0.0320	0.0349
Curriculum metoda	0.1304	0.0680	0.0639

Random InfoNCE ostvaruje najbolje performanse prema Recall@10 metrici.

Rang relevantnih filmova

Model	Prosečan rang	Top-1 tačnost
BPR	151	0.017
Random InfoNCE	**79**	**0.031**

- InfoNCE model u proseku rangira relevantne filmove znatno bliže vrhu liste.
- Top-1 tačnost je skoro **duplo veća** u odnosu na BPR.

Primer generisanih preporuka

Ulazni filmovi

- Star Wars (1977)
- The Godfather (1972)
- The Terminator (1984)

Generisane preporuke

- The Empire Strikes Back (1980)
- Terminator 2 (1991)
- Alien (1979)
- Raiders of the Lost Ark (1981)
- Pulp Fiction (1994)

Vizualizacija embedding prostora

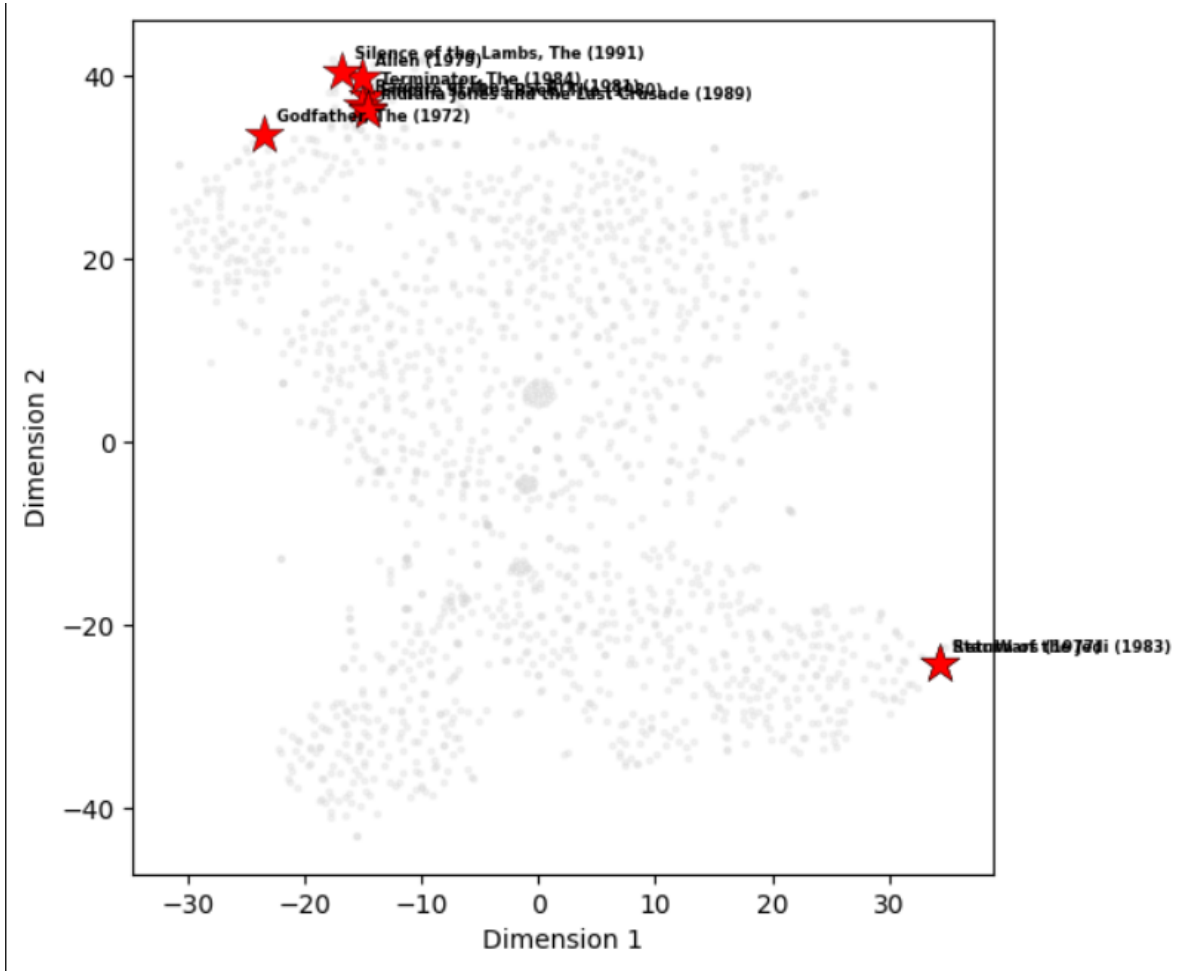

Zaključak

- Contrastive learning predstavlja moćan pristup učenju reprezentacija.
- U sistemima preporuke omogućava bolje razdvajanje pozitivnih i negativnih primera.
- Eksperimenti pokazuju da performanse zavise od:
  - strategije negativnog uzorkovanja
  - temperature
  - veličine embedding prostora
- Contrastive pristupi predstavljaju obećavajući pravac razvoja sistema preporuke.